

Etapa 4 — Resultados dos Testes e Reflexão Crítica

Autor

Marcus Vinícius Santos de Almeida

Data de entrega

11/09/2026

Cobre os entregáveis

"Resultados dos testes" (5+ casos com análise) e "Reflexão crítica"

Artefatos

testes/casos_teste.csv

testes/rodar_casos_teste.py

testes/resultados_casos.txt

Modelo de treino

1.000.000 de módulos sintéticos (Naive Bayes puro) · $P(\text{SIM}) = 350.000/1.000.000 = 0,3500$ · $P(\text{NÃO}) = 650.000/1.000.000 = 0,6500$

Todos os números saem de `python3 testes/rodar_casos_teste.py` (DuckDB), rodado sobre a massa de dados atual — 6 features independentes entre si, $N = 1.000.000$. Esta é a **terceira revisão** da massa de dados do projeto (dados correlacionados → $N=150$ independente → $N=1.000.000$ independente) — cada mudança de dados muda os números, não a lógica do classificador nem a tese da Reflexão Crítica (§5).

1 Os 6 casos de teste

Os perfis são os mesmos das versões anteriores — o que mudou foi apenas a massa de treino sobre a qual são classificados.

Caso	Propósito	complex.	loc	autores	churn	imports	cobertura	Intuição
a	Baixo risco claro — tudo bom	baixo	medio	baixo	baixo	baixo	alto	BAIXO
b	Alto risco claro — tudo ruim	alto	alto	alto	alto	alto	baixo	ALTO
c	Ambíguo — complexidade alta e cobertura alta	alto	medio	medio	medio	medio	alto	~50/50
d	Armadilha de Koru, sem bônus de interação — pequeno e denso	alto	baixo	medio	medio	medio	medio	ALTO
e	Combinação rara — grande porém simples, churn alto	baixo	alto	baixo	alto	baixo	alto	BAIXO / indef.

f	Feature contestada — tudo ruim, cobertura alta	alto	alto	alto	alto	alto	alto	ALTO
---	--	------	------	------	------	------	------	------

2 Resultados

Caso	P(SIM)	P(NÃO)	Recomendação	Bate com a intuição?
a	4,41%	95,59%	BAIXO RISCO	Sim
b	95,26%	4,74%	ALTO RISCO	Sim
c	49,08%	50,92%	BAIXO RISCO	Sim, e de forma mais literal — a poucas décimas de 50/50, a marca mais nítida de "ambíguo" das 3 versões
d	67,26%	32,74%	ALTO RISCO	Sim, com folga maior que com N=150 (55,5%) — sem reintroduzir interação, ver §4.1
e	23,46%	76,54%	BAIXO RISCO	Sim (ressalva sobre confiança — §4.3)
f	92,83%	7,17%	ALTO RISCO	Sim — cobertura alta não "salvou" o módulo

As duas probabilidades somam 100,00% em todos os casos; 6/6 features casaram com a tabela de verossimilhanças.

2.1 Como cada resultado se forma

Log-odds a priori: $\ln(350.000/650.000) = -0,619$ (a base já pende para NÃO); soma-se o log-odds de cada categoria (tabela §3). $P(\text{SIM}) > 50\% \Leftrightarrow \text{soma total} > 0$.

- **Caso a** — soma = -2,46; total -3,08 → P(SIM) 4,4%. Todas categorias "boas" com log-odds negativo. Correto.
- **Caso b** — soma = +3,62; total +3,00 → P(SIM) 95,3%. Espelho do caso a.
- **Caso c** — soma = +0,58; total -0,04 → P(SIM) 49,1%. Complexidade=alto vale +0,98 sozinha, mas autores=medio (-0,12), imports=medio (-0,09), loc=medio (-0,21) e cobertura=alto (-0,22) quase empatam o placar. Com N=150 este perfil dava 38,0% BAIXO; com N=1.000.000, os log-odds convergem para os pesos "verdadeiros" do gerador, e por **coincidência** (não por desenho) este perfil fica quase exatamente no ponto de equilíbrio.
- **Caso d** — soma = +1,34; total +0,72 → P(SIM) 67,3%. loc=baixo (+0,36) + complexidade=alto (+0,98) somam +1,34; as outras 4 (todas medio) somam ≈0. Mais alto que os 55,5% com N=150 — não por bônus de interação (não há nenhum), mas porque os log-odds individuais convergiram para mais perto dos pesos reais do gerador ($\text{PESOS}["cc"]["alto"] = 0,75$, $\text{PESOS}["loc"]["baixo"] = 0,45$). Discussão completa em §4.1.
- **Caso e** — soma = -0,56; total -1,18 → P(SIM) 23,5%. churn=alto (+1,15) puxa para SIM, mas é superado por complexidade=baixo (-0,48), autores=baixo (-0,72), imports=baixo (-0,35) e cobertura=alto (-0,22).

- **Caso f** — soma = +3,18; total +2,56 → P(SIM) 92,8%. Caso b com cobertura trocada para alto: caiu de 95,26% para 92,83% (cobertura=baixo tem log-odds +0,22, alto tem -0,22 — direção "intuitiva" desta vez). Mesmo assim, ALTO RISCO com folga.

3 Poder discriminativo das features (log-odds)

Feature	baixo	médio	alto	Formato
n_autores	-0,72	-0,12	+0,93	monótono forte
complexidade	-0,48	+0,32	+0,98	monótono
churn	-0,48	+0,24	+1,15	monótono, salto grande no alto
loc	+0,36	-0,21	+0,05	em U (baixo e alto arriscados)
cobertura	+0,22	-0,03	-0,22	monótono fraco (direção "intuitiva")
n_imports	-0,35	-0,09	+0,29	monótono

3.1 Ranking por |log-odds| médio

1. Churn relativo		0,625
2. Nº de autores		0,592
3. Complexidade		0,591
4. Nº de imports		0,241
5. LOC		0,207
6. Cobertura		0,157

O ranking mudou de ordem de novo — por que isso não é instabilidade

Com $N=150$ a ordem era autores > complexidade > churn > loc > cobertura > imports. Com $N=1.000.000$: churn > autores > complexidade > imports > loc > cobertura. As features já eram independentes nas duas versões — o que mudou foi só o tamanho da amostra. Os três primeiros lugares (churn, autores, complexidade) têm amplitude de peso parecida no gerador (1,10 a 1,25), então qual fica em 1º/2º/3º é sensível a detalhes finos mesmo com 1 milhão de registros — erro-padrão $\propto 1/\sqrt{N}$, o mesmo princípio da Etapa 2. Nº de imports subiu de 6º para 4º porque sua amplitude real (0,50) é maior que a de LOC (0,45) — só não aparecia com $N=150$ por ruído de amostragem. Cobertura de testes segue, nas duas versões, a menos discriminativa — distância grande o bastante para não depender do tamanho da amostra.

4 Análise — as 4 perguntas da atividade

4.1 (a) O modelo classificou conforme a intuição do domínio?

- **Casos a e b:** acertos limpos, 4,4% e 95,3%.
- **Caso c:** 49,1% — a 1 ponto percentual de 50/50, a marca mais nítida de "ambíguo" das três versões deste relatório (61% ALTO com dados correlacionados; 38% BAIXO com N=150; agora 49,1% BAIXO com N=1.000.000). A proximidade crescente de 50/50 é coincidência de como este perfil interage com os pesos do gerador, não um objetivo de projeto.
- **Caso d — a "armadilha de Koru", agora com estimativas mais precisas.** Na versão original (dados correlacionados), o gerador somava um bônus de +0,70 sempre que loc=baixo e complexidade=alto ocorriam juntas, dando $P(\text{SIM})=74,40\%$. Desde "Naive Bayes puro", essa dependência foi removida: o resultado atual (67,26%) é, por construção, **exatamente** a soma dos dois efeitos individuais — loc=baixo isolado (+0,36) mais complexidade=alto isolado (+0,98), sem bônus. É mais alto que os 55,5% com N=150 não porque uma interação foi reintroduzida, mas porque os log-odds individuais convergiram para mais perto dos pesos reais do gerador com mais dados.
- **Caso e:** plausível (23,5% BAIXO), com ressalva de §4.3.
- **Caso f:** cobertura alta reduziu discretamente o risco (95,26% → 92,83%), mas não o suficiente — as outras 5 features ruins dominam.

4.2 (b) Quais features tiveram maior log-odds?

1. **Churn relativo** lidera (0,625; alto = +1,15, o maior valor máximo isolado).
2. **Nº de autores** logo atrás (0,592; alto = +0,93).
3. **Complexidade** fecha o pódio, quase empatada (0,591; alto = +0,98, a categoria individual mais forte da tabela).
4. **Nº de imports** salta para 4º (0,241) — era último com N=150.
5. **LOC:** log-odds em U — baixo (+0,36) e alto (+0,05) empurram para SIM, medio (−0,21) para NÃO. Continua capturando a não-linearidade de Koru, propriedade isolada de LOC.
6. **Cobertura:** a menos discriminativa (0,157), efeito pequeno e agora na direção "intuitiva" — consistente com a literatura contestada.

4.3 (c) O caso raro/fronteira (caso e) e o papel de Laplace

O perfil do caso e é raro, mas — diferente das versões com N=150 — **não está mais totalmente ausente** do treino: aparece em **47 dos 1.000.000** de módulos (contra 0/150 antes). Com $3^6 = 729$ combinações possíveis, 1.000.000 de exemplos já faz até perfis de baixa probabilidade conjunta aparecerem algumas dezenas de vezes. O classificador devolve $P(\text{NÃO}) = 76,5\%$.

Por que ele consegue responder mesmo quando o perfil é raro

O Naive Bayes só usa as seis fatias unidimensionais $P(\text{categoria}|\text{classe})$ — a menos populosa das 36 combinações $\text{feature} \times \text{categoria} \times \text{classe}$ ainda tem quase 30 mil observações. A esparsidade da combinação de 6 categorias não trava o modelo. É a força do Naive Bayes — e também seu risco: ele soa confiante (77/23) sobre uma combinação rara no treino, mesmo com N grande.

O que a suavização de Laplace faz aqui

A célula mais rara de todas é $\text{churn}=\text{alto}$ na classe NÃO: 29.682 de 650.000 — ainda uma contagem grande. Sem suavização, $P \approx 0,045665$; com Laplace, $(29.682+1)/(650.000+3) \approx 0,045666$ — diferença na quarta casa decimal, irrelevante. Com $N=150$, a mesma correção tinha efeito proporcional visível; com $N=1.000.000$, a correção fixa (+1, +3) é desprezível frente a qualquer contagem observada. Continua presente e correta — só que com efeito prático cada vez menor conforme N cresce.

4.4 (d) Limitações do Naive Bayes neste domínio

1. A independência testada é verdadeira por construção, não por realismo

Esta é a limitação central, igual às versões anteriores — só mudou o quanto os dados a confirmam: agora todos os $|r| \leq 0,002$ (contra $<0,10$ com $N=150$). Não há, neste dataset, nenhuma violação empírica para medir — a análise não afirma ter encontrado uma; o aumento de N só reforça essa afirmação, não a muda. O que existe é limitação **teórica**, documentada na literatura: em código real, complexidade e LOC são fortemente correlacionadas ($R^2 \approx 0,93$ — Shepperd, 1988). É uma limitação do realismo da simulação, e nenhuma quantidade de dados sintéticos adicionais muda isso, porque a limitação está em *como* os dados são gerados, não no tamanho da amostra.

2. O Naive Bayes não modela interação — nem para mais, nem para menos. O caso d evidencia isso de forma limpa: sem termo de interação, o resultado para "pequeno e denso" é exatamente a soma dos dois efeitos individuais. Se, num cenário real, o efeito combinado fosse maior que a soma das partes (o que Koru et al. sugere ser plausível), o Naive Bayes subestimaria esse risco — não porque os dados escondem a interação, mas porque o modelo não tem como representá-la.

3. Relação não-linear de LOC. Continua valendo e não depende de correlação com outra feature — propriedade de LOC isolado, coerente com Koru et al. (2008).

4. Cobertura de testes: evidência contestada. Segue entre as duas features menos discriminativas, com efeito pequeno (caso f). Limitação assumida e documentada.

5. Módulo = arquivo, não classe. Inalterado — custo de métricas mais "grossas" por registro.

6. Dados de treino sintéticos. O rótulo depende das 6 features de forma independente, mas ainda é definido por pesos escolhidos pelo autor a partir da literatura — a validação contra a "intuição do domínio" continua, em parte, circular quanto a essa direção individual (não quanto à interação, que não existe mais).

5 Reflexão crítica

Este projeto testou o Naive Bayes exatamente no cenário em que sua suposição central — independência condicional entre features dado o rótulo — é verdadeira por construção dos dados. Os resultados confirmam que, nesse cenário, o modelo se comporta exatamente como a teoria prevê: separa com folga os módulos claramente arriscados dos claramente seguros (casos a e b, 4% vs. 95%), responde de forma bem definida a um perfil raro no treino porque só depende de fatias unidimensionais bem povoadas (caso e), e, no caso mais revelador (caso d), produz exatamente a soma dos dois efeitos marginais de "LOC baixo" e "complexidade alta" — nem mais, nem menos — porque não há, nos dados, nenhum termo de interação para capturar. Passar de $N=150$ para $N=1.000.000$ não mudou nenhuma conclusão qualitativa; mudou números de segunda casa decimal e deixou a matriz de correlação ainda mais perto de zero — reforça, sem alterar, o argumento seguinte.

Isso é bom e ruim ao mesmo tempo. É **bom** porque valida a implementação: o SQL soma priors e verossimilhanças em log corretamente, aplica Laplace corretamente, e produz decisões coerentes com os pesos que geraram os dados — se houvesse um bug na Etapa 3, este seria o cenário mais fácil de expor um comportamento errado, e não expôs nenhum. É **limitado** porque este é o cenário mais favorável possível para um Naive Bayes, não o de um sistema real em produção. Em código real, complexidade e LOC são correlacionadas com força ($R^2 \approx 0,93$ — Shepperd, 1988), e o Naive Bayes, ao tratá-las como independentes, contaria a evidência de "tamanho/estrutura do código" duas vezes. Este projeto não mediu esse efeito porque optou, de propósito, por não reproduzi-lo — é uma limitação **teórica**, documentada na literatura, não uma violação encontrada empiricamente nesta massa de dados.

Veredito honesto

O modelo implementado está correto e bem testado dentro do cenário para o qual foi desenhado — um Naive Bayes "em sua forma pura". Antes de usá-lo sobre dados reais de um repositório de verdade, seria necessário reavaliar a suposição de independência sobre a massa real (medir a correlação entre complexidade e LOC nesse repositório) e, se ela se confirmar como na literatura, considerar reduzir a redundância (fundir as duas features, ou trocar por um modelo que aceite correlação, como regressão logística) antes de confiar nas probabilidades absolutas — não só na ordenação relativa dos módulos.

6 Desempenho

Com N passando de 150 para 1.000.000, faz sentido **medir** — não só assumir — que o pipeline continua rodando em segundos. Os números vêm direto dos scripts, que instrumentam seu próprio tempo de execução (`time.perf_counter`).

Etapa	O que mede	Tempo
Etapa 2 — geração dos dados	1.000.000 de módulos sintéticos (numpy vetorizado + pandas), ponta a ponta	11,88 s

Etapa 3 — importação do CSV	<code>read_csv_auto</code> → tabela <code>dados_treinamento</code> (1.000.000 de linhas)	3,33 s
Etapa 4 — classificar os 6 casos	Conectar, importar o CSV de treino, criar as views, classificar os 6 casos, ponta a ponta	4,12 s

O pipeline inteiro continua na casa dos segundos, não minutos. A etapa mais lenta é a geração dos dados; Etapas 3 e 4 recriam o banco DuckDB do zero (importação + views + classificação) em poucos segundos, mesmo com `treino_longo` chegando a 6.000.000 de linhas.

Classificar um caso novo não fica mais lento com N maior

A consulta que classifica um perfil de 6 categorias usa só a view `verossimilhancas`, de tamanho **fixo** — 6 features × 3 categorias × 2 classes = 36 linhas — não importa se o treino tem 150 ou 1.000.000 de módulos. O Naive Bayes usa apenas essas 36 fatias unidimensionais de $P(\text{categoria}|\text{classe})$, nunca uma busca sobre `dados_treinamento` inteiro; por isso o custo de classificar um caso não escala com N.

Nota sobre o uso de IA

Os casos de teste, o script de execução e esta análise foram construídos em diálogo com uma IA generativa. Cada resultado numérico foi reproduzido pelo script (`testes/rodar_casos_teste.py`) e conferido contra a decomposição em log-odds; as limitações teóricas foram checadas contra as referências da Etapa 1. A tese central — a distinção entre "limitação teórica documentada na literatura" e "violação encontrada empiricamente nos dados" — foi definida como decisão de projeto antes da geração dos dados, não inferida depois de olhar os resultados. Todo o conteúdo é defensável oralmente.