

Atividade Prática 1 — Classificador Bayesiano

Etapa 4 — Resultados dos Testes e Reflexão Crítica

Autor	Marcus Vinícius Santos de Almeida
Disciplina	Mineração de Dados
Data de entrega	04/09/2026
Cobre os entregáveis	"Resultados dos testes" (5+ casos com análise) e "Reflexão crítica"
Artefatos	testes/casos_teste.csv · testes/rodar_casos_teste.py · testes/resultados_casos.txt
Modelo de treino	150 módulos sintéticos da Etapa 2 (decisão "Naive Bayes puro" — features independentes entre si) · $P(\text{SIM}) = 52/150 = 0,347$ · $P(\text{NAO}) = 98/150 = 0,653$

Todos os números deste relatório saem de `python3 testes/rodar_casos_teste.py` (que reconstrói o banco, roda os 6 casos e calcula os log-odds a partir da view `verossimilhancas` da Etapa 3), rodado sobre a massa de dados da versão atual da Etapa 2 — 6 features geradas independentes entre si (ver `CLAUDE.md`, seção "Naive Bayes puro", e o relatório da Etapa 2, §1.2).

1. Os 6 casos de teste

Cada caso usa as 6 features e as faixas `baixo/medio/alto` do `CLAUDE.md`. Os perfis são os mesmos da versão anterior deste relatório — o que mudou foi apenas a massa de treino sobre a qual eles são classificados.

Caso	Propósito	complexidade	loc	n_autores	churn	n_imports	cobertura	Intuição
a	Baixo risco claro — tudo bom	baixo	medio	baixo	baixo	baixo	alto	BAIXO
b	Alto risco claro — tudo ruim	alto	alto	alto	alto	alto	baixo	ALTO
c	Ambíguo — sinais contraditórios (complexidade alta e cobertura alta)	alto	medio	medio	medio	medio	alto	~50/50
d	Armadilha de Koru, sem bônus de interação — arquivo pequeno e denso	alto	baixo	medio	medio	medio	medio	ALTO
e	Combinação rara / fronteira — arquivo grande porém simples, churn alto	baixo	alto	baixo	alto	baixo	alto	BAIXO/ indefinido
f	Feature contestada — tudo ruim, mas cobertura alta	alto	alto	alto	alto	alto	alto	ALTO

2. Resultados

Caso	P(SIM)	P(NAO)	Recomendação	Bate com a intuição?
a	4,28%	95,72%	BAIXO RISCO	Sim
b	95,53%	4,47%	ALTO RISCO	Sim
c	38,04%	61,96%	BAIXO RISCO	Parcial — perto de 50/50 como esperado, mas agora do lado NÃO (era ALTO na versão anterior deste relatório; ver discussão abaixo)
d	55,52%	44,48%	ALTO RISCO	Sim, mas por pouco — sem bônus de interação, o resultado fica bem mais perto da fronteira do que na versão anterior (era 74,40%)
e	22,14%	77,86%	BAIXO RISCO	Sim (com ressalva sobre confiança — ver §4.3)
f	92,64%	7,36%	ALTO RISCO	Sim — cobertura alta reduz um pouco o risco frente ao caso b, mas não o suficiente para "salvar" o módulo

As duas probabilidades somam 100,00 % em todos os casos e as 6 features casaram com a tabela de verossimilhanças (`n_features = 6/6`).

Como cada resultado se forma

O classificador é, na prática, um **somatório de log-odds**: começa no log-odds a priori `ln(52/98) = -0,633` (a base já pende para NAO) e soma o log-odds de cada categoria observada (tabela do §3). `P(SIM) > 50 %` $\Leftrightarrow$ soma total > 0 .

- **Caso a** — soma das features = -2,47; com o prior, total -3,11 $\rightarrow$ P(SIM) 4 %. Todas as categorias "boas" têm log-odds negativo; o modelo acumula evidência contra defeito. Correto.
- **Caso b** — soma das features = +3,70; total +3,06 $\rightarrow$ P(SIM) 96 %. Espelho do caso a. Correto.
- **Caso c** — soma das features = +0,15; total -0,49 $\rightarrow$ P(SIM) 38 %. A `complexidade = alto` sozinha vale **+0,76**, mas `n_autores = medio` (-0,14), `n_imports = medio` (-0,07) e sobretudo `loc = medio` (-0,26) e `cobertura = alto` (-0,15) puxam na direção contrária o suficiente para virar o placar. Na versão anterior deste relatório (dados com correlações plantadas) esse mesmo perfil dava ALTO RISCO (61 %); aqui dá BAIXO RISCO (38 %). Não é um erro: é o resultado esperado de mudar os dados de treino — os pesos por categoria de cada feature mudaram porque a massa de dados é outra, e o caso continua sendo, como o nome propõe, o mais perto de 50/50 dos seis.
- **Caso d** — soma das features = +0,86; total +0,22 $\rightarrow$ P(SIM) 55,5 %. Aqui está o ponto de Koru, sem bônus de interação: `loc = baixo` tem log-odds **+0,45** (empurra para SIM, não para NAO) e `complexidade = alto` tem **+0,76** — juntas somam +1,21, e as outras 4 features (todas `medio`) somam -0,35, resultando no total acima. O modelo classifica o arquivo pequeno-e-denso como ALTO RISCO, mas agora **por pouco** (55,5 % vs. 44,5 %) — não pelos 74,4 % da versão anterior, que incluía um bônus de interação plantado de propósito no gerador antigo. Discussão completa em §4.1.
- **Caso e** — soma das features = -0,62; total -1,26 $\rightarrow$ P(SIM) 22 %. O `churn = alto` (+1,20) puxa para SIM, mas é superado por `complexidade = baixo` (-0,61), `n_autores = baixo` (-0,93), `n_imports = baixo` (-0,27) e `cobertura = alto` (-0,15). Resultado: BAIXO RISCO. Discussão em §4.3.
- **Caso f** — soma das features = +3,17; total +2,53 $\rightarrow$ P(SIM) 93 %. É o caso b com `cobertura` trocada de `baixo` para `alto`. O resultado **caiu** de 95,53 % para 92,64 %: no treino atual, `cobertura = baixo` tem log-odds +0,37 e `cobertura = alto` tem -0,15 — dessa vez cobertura se comporta na direção "intuitiva" (mais cobertura, menos risco), ao contrário da versão anterior deste relatório, em que o efeito ia na direção contrária. Mesmo assim, o módulo continua ALTO RISCO com folga: a diferença entre os dois casos ($\approx 0,52$ de log-odds) é pequena perto da soma das outras 5 features ruins ($\approx +3,17$). Ver §4.4 e §5.

3. Poder discriminativo das features (log-odds)

Log-odds de uma categoria = $\ln(P(\text{categoria} \mid \text{SIM}) / P(\text{categoria} \mid \text{NAO}))$, o "peso de evidência" daquela categoria: positivo empurra a classificação para SIM, negativo para NAO, e |valor| grande = categoria informativa.

Log-odds por categoria

Feature	baixo	medio	alto	Formato
n_autores	-0,93	-0,14	+1,01	monótono forte
complexidade	-0,61	+0,41	+0,76	monótono
churn	-0,25	+0,01	+1,20	monótono, salto grande no alto
loc	+0,45	-0,26	+0,15	em U (baixo e alto arriscados, mediano protege)
cobertura	+0,37	-0,15	-0,15	monótono fraco (direção "intuitiva" desta vez)
n_imports	-0,27	-0,07	+0,20	monótono fraco

Ranking por |log-odds| médio (poder discriminativo)

#	Feature	log-odds médio	log-odds máx
1	nº de autores	0,695	1,013
2	complexidade ciclomática	0,595	0,762
3	churn relativo	0,482	1,196
4	LOC	0,285	0,445
5	cobertura de testes	0,227	0,374
6	nº de imports	0,180	0,268

Note-se que o ranking **mudou de ordem** em relação à versão anterior deste relatório (lá: complexidade > imports > autores > loc > churn > cobertura). Isso é esperado: os pesos de rótulo por categoria (**PESOS** no gerador) são os mesmos de antes, mas agora cada feature é sorteada de forma independente das demais, então a *frequência exata* de cada categoria dentro de cada classe — e portanto o log-odds calculado sobre a amostra de 150 módulos — depende só do sorteio daquela feature, não mais de covariar com outra. Cobertura de testes continua entre as duas features menos discriminativas, consistente com a literatura contestada sobre essa métrica.

4. Análise — as 4 perguntas da atividade

4.1 (a) O modelo classificou conforme a intuição do domínio?

Em geral, sim, com um contraste pedagógico importante no caso d. Os dois casos "extremos" (a e b) saíram exatamente como o domínio prevê. Caso a caso:

- **Casos a e b** (baixo/alto risco claros): acertos limpos, 4 % e 96 % de P(SIM). O modelo empilha evidência coerente.
- **Caso c** (ambíguo): o resultado (38 %, BAIXO RISCO) inverteu de lado frente à versão anterior deste relatório (61 %, ALTO RISCO), mas continua sendo, dos seis, o mais perto de 50/50 — a marca de um caso genuinamente ambíguo não é sempre cair do mesmo lado, é cair perto da fronteira. A mudança de lado é consequência de trocar a massa de treino (Etapa 2), não um defeito do classificador.
- **Caso d — a "armadilha de Koru", agora sem bônus de interação plantado.** Este é o caso mais importante para entender a diferença entre esta versão do projeto e a anterior. Na versão anterior, o gerador da Etapa 2 somava um **bônus explícito** de +0,70 ao score de risco sempre que **loc = baixo e complexidade = alto** ocorriam juntas — um efeito de interação plantado de propósito, e o resultado era P(SIM) = 74,40 %. Nesta versão, essa dependência entre features foi removida do gerador (decisão "Naive Bayes puro" — Etapa 2, §1.2): o rótulo continua

dependendo de cada feature, mas **não há mais nenhum termo que dependa da combinação das duas**. O resultado ($P(\text{SIM}) = 55,52\%$) é, por construção, exatamente a soma dos dois efeitos individuais — o log-odds de `loc = baixo` isolado (+0,45) mais o log-odds de `complexidade = alto` isolado (+0,76), ajustado pelas outras 4 features e pelo prior — **sem nenhum bônus extra**. O modelo ainda classifica o arquivo pequeno-e-denso como ALTO RISCO (a soma dos dois efeitos positivos é suficiente para passar de 50 %), mas por uma margem pequena, bem diferente da confiança de 74 % da versão anterior. Isso demonstra exatamente o que o Naive Bayes faz e não faz: ele **soma evidências marginais**, nunca modela um efeito de interação que exceda a soma das partes — quando não há interação plantada nos dados, o resultado reflete apenas essa soma, sem "descontos" nem "bônus" adicionais.

- **Caso e** (raro): resultado plausível (BAIXO RISCO, 22 %), com a ressalva de §4.3 sobre o modelo soar confiante para um perfil nunca visto no treino.
- **Caso f** (cobertura contestada): a cobertura alta reduziu discretamente o risco frente ao caso b ($95,53\% \rightarrow 92,64\%$), mas não o suficiente para tirar o módulo de ALTO RISCO — as outras 5 features ruins dominam. Ao contrário da versão anterior deste relatório, aqui a cobertura se comporta na direção "intuitiva" (mais cobertura, menos risco); mesmo assim seu efeito é pequeno frente às demais features, consistente com a literatura que trata essa relação como fraca/contestada (§4.2).

4.2 (b) Quais features tiveram maior log-odds (maior poder discriminativo)?

Ranking do §3:

1. **Nº de autores distintos** lidera desta vez ($|\log\text{-odds}|$ médio 0,695; a categoria `alto` sozinha vale +1,01).
2. **Complexidade ciclomática** vem em seguida (0,595; `alto` = +0,76).
3. **Churn relativo** tem o maior valor máximo isolado da tabela (`alto` = +1,20), mas média um pouco menor (0,482) porque `baixo` e `medio` pesam pouco.
4. **LOC** é o caso mais interessante estruturalmente: o log-odds é **em U** — `baixo` (+0,45) e `alto` (+0,15) empurram para SIM, `medio` (−0,26) para NAO. O modelo continua capturando a não-linearidade de Koru (§4.1, caso d), e isso não depende de LOC estar correlacionado com nenhuma outra feature — é uma propriedade da relação entre LOC e o rótulo, isolada.
5. **Cobertura de testes** é a **segunda menos discriminativa** ($|\log\text{-odds}|$ médio 0,227), com efeito pequeno e agora na direção "intuitiva" — ainda assim, pequeno demais para mudar uma classificação por conta própria (caso f). Consistente com a literatura que trata a relação cobertura↔defeitos como contestada (Inozemtseva & Holmes, 2014; Gren & Antinyan, 2017).
6. **Nº de imports** é a **menos discriminativa** de todas ($|\log\text{-odds}|$ médio 0,180; máximo 0,268).

O fato de o ranking ter mudado de ordem frente à versão anterior (lá, complexidade liderava com folga) é esperado e reforça a Seção 5: quando as features passam a ser sorteadas de forma independente, cada uma carrega exatamente a informação da sua própria distribuição — nenhuma "empresta" poder discriminativo de outra por estarem correlacionadas.

4.3 (c) O caso de valor não visto / na fronteira (caso e) e o papel de Laplace

O perfil do caso e (`complexidade baixo`, `loc alto`, `n_autores baixo`, `churn alto`, `n_imports baixo`, `cobertura alto`) **não aparece em nenhum dos 150 módulos de treino** (perfil exato no treino = 0). Ainda assim o classificador devolve uma resposta bem definida: $P(\text{NAO}) = 77,9\%$.

Por que ele consegue responder. O Naive Bayes nunca precisa ter visto o perfil completo — pela hipótese de independência, ele só usa as **seis fatias unidimensionais** $P(\text{categoria} | \text{classe})$, e cada uma dessas fatias está bem povoada. Ou seja, a esparsidade da combinação de 6 categorias (729 perfis possíveis, 150 exemplos) não trava o modelo. Essa é a **força** do Naive Bayes — e também o seu risco: ele soa confiante (78/22) sobre uma combinação que talvez mereça mais incerteza justamente por nunca ter sido observada por inteiro.

O que a suavização de Laplace faz aqui. Com este dataset, a categoria mais rara de todas é `n_autores = baixo` na classe SIM: apenas 6 dos 52 módulos com defeito. Sem suavização, $P(n_autores=baixo|SIM)$ seria $6/52 \approx 0,115$; com Laplace, $(6+1)/(52+3) = 7/55 \approx 0,127$. Nenhuma célula

(feature, categoria, classe) deste dataset está vazia, então Laplace não precisou impedir nenhum $\ln(0)$ neste teste específico — o que ele fez foi encolher levemente cada estimativa na direção do uniforme, como sempre faz.

Quando Laplace seria decisivo. Se tivéssemos discretizado em mais faixas, ou com menos dados, alguma célula ficaria em 0 e — sem suavização — $\ln(0) = -\infty$ zeraria a classe inteira por causa de **uma** categoria não observada. Com Laplace essa célula valeria $1/55 \approx 0,018$ em vez de 0, e a classe continuaria "viva" para as outras 5 features decidirem. É uma apólice de seguro que, neste conjunto de dados específico, não precisou ser acionada — mas que mantém o modelo bem-definido para qualquer entrada.

4.4 (d) Limitações do Naive Bayes neste domínio

1. **A independência entre features testada aqui é verdadeira por construção, não por realismo.** Esta é a limitação central desta versão do projeto, e é diferente da limitação discutida na versão anterior. Os dados de treino da Etapa 2 foram gerados com as 6 features estatisticamente independentes entre si (decisão "Naive Bayes puro" — CLAUDE.md), e a matriz de correlação da Etapa 2 confirma isso (todos os $|r| < 0,10$). Isso significa que **não há**, neste dataset, nenhuma violação empírica de independência para medir — e a análise abaixo não afirma ter encontrado uma. O que existe é uma limitação **teórica, documentada na literatura**: em código real, complexidade ciclomática e LOC são fortemente correlacionadas ($R^2 \approx 0,93$ — Shepperd, 1988; Seção 5 do relatório da Etapa 1). Um classificador treinado sobre dados sintéticos independentes se comporta exatamente como a teoria do Naive Bayes prevê (soma de evidências marginais, sem "contar duas vezes"), mas isso não garante o mesmo comportamento sobre uma massa de dados real, onde essa correlação existiria de fato. A distinção importa: é uma limitação **do realismo da simulação**, não um erro encontrado nos dados nem um erro de implementação do classificador.
2. **O Naive Bayes não modela interação entre features — nem para mais, nem para menos.** O caso d (§4.1) evidencia isso de forma limpa: sem nenhum termo de interação nos dados, o resultado para "pequeno e denso" é exatamente a soma dos dois efeitos individuais (LOC baixo + complexidade alta), nem mais nem menos. Se, em um cenário real, o efeito combinado de "pequeno e denso" fosse **maior** do que a soma das partes (o que a teoria de Koru et al. sugere ser plausível), o Naive Bayes subestimaria esse risco — não porque os dados de treino "escondam" a interação, mas porque o modelo, por definição, não tem como representar termos de interação.
3. **Relação não-linear de LOC com risco.** Isso continua valendo e **não** depende de LOC estar correlacionado com outra feature: a discretização em 3 faixas captura a forma em U (§3) porque o peso atribuído a **loc = baixo** na geração dos dados é individualmente maior que o de **loc = medio** — uma propriedade de LOC isolado, coerente com Koru et al. (2008).
4. **Feature de evidência contestada: cobertura de testes.** Continua entre as duas features menos discriminativas do ranking (§3), com efeito pequeno sobre o score final (caso f). Mantê-la é uma limitação assumida e documentada, não um descuido.
5. **Simplificação módulo = arquivo (e não classe).** Inalterada frente à versão anterior: o estudo de referência (Koru et al.) usa classe como unidade; adotamos arquivo por ser universal e não exigir parser por linguagem, ao custo de métricas mais "grossas" por registro.
6. **Dados de treino sintéticos.** Os 150 módulos foram gerados por script (Etapa 2). Diferente da versão anterior, o rótulo aqui depende das 6 features de forma independente, mas o rótulo em si ainda é definido por pesos escolhidos pelo autor a partir da literatura — a validação contra a "intuição do domínio" continua, em parte, circular quanto a essa direção individual de cada feature (mesmo não sendo mais circular quanto à interação entre elas).

5. Reflexão Crítica

Este projeto testou o classificador Naive Bayes exatamente no cenário em que a sua própria suposição central — independência condicional entre features dado o rótulo — é **verdadeira por construção dos dados**. Os resultados confirmam que, nesse cenário, o modelo se comporta **exa-**

tamente como a teoria prevê: separa com folga os módulos claramente arriscados dos claramente seguros (casos a e b, 4 % vs 96 %), responde de forma bem definida a um perfil nunca visto no treino porque só depende de fatias unidimensionais bem povoadas (caso e, §4.3), e, no caso mais revelador (caso d), produz exatamente a **soma** dos dois efeitos marginais de "LOC baixo" e "complexidade alta" — nem mais, nem menos — porque não há, nos dados, nenhum termo de interação para o modelo capturar ou deixar de capturar.

Isso é bom e é ruim ao mesmo tempo, e é importante não confundir as duas coisas. É **bom** porque valida a implementação: o classificador SQL soma priors e verossimilhanças em log corretamente, aplica Laplace corretamente e produz decisões coerentes com os pesos que geraram os dados — se houvesse um bug na Etapa 3, este seria o cenário mais fácil de expor um comportamento errado, e não expôs nenhum. É **limitado** porque este é o cenário mais favorável possível para um Naive Bayes, e não é o cenário de um sistema real em produção. Em código real, complexidade ciclomática e LOC são correlacionadas com força ($R^2 \approx 0,93$ — Shepperd, 1988), e o Naive Bayes, ao tratá-las como independentes, contaria a evidência de "tamanho/estrutura do código" duas vezes, ficando mais confiante do que deveria exatamente nos casos onde essas features concordam. Este projeto **não mediu** esse efeito porque optou, de propósito, por não reproduzi-lo nos dados sintéticos (Etapa 2, §1.2) — então é preciso ser preciso sobre o que está sendo afirmado aqui: isto é uma limitação **teórica, documentada na literatura consultada na Etapa 1**, não uma violação **encontrada empiricamente** nesta massa de dados. A matriz de correlação da Etapa 2 saiu com todos os $|r|$ abaixo de 0,10 — não há, neste dataset, nada para "descobrir" nesse sentido.

O veredito honesto: o modelo implementado está correto e bem testado dentro do cenário para o qual foi desenhado — um Naive Bayes "em sua forma pura". Antes de usá-lo sobre dados reais de um repositório de verdade, seria necessário reavaliar a suposição de independência sobre a massa real (medir a correlação entre complexidade e LOC nesse repositório, por exemplo) e, se ela se confirmar como na literatura, considerar reduzir a redundância (fundir as duas features, ou trocar por um modelo que aceite correlação, como regressão logística) antes de confiar nas probabilidades absolutas — não só na ordenação relativa dos módulos — que o classificador produz.

Nota sobre o uso de IA

Os casos de teste, o script de execução e esta análise foram construídos em diálogo com uma IA generativa. Cada resultado numérico foi reproduzido pelo script (`testes/rodar_casos_teste.py`) e conferido contra a decomposição em log-odds; as limitações teóricas foram checadas contra as referências levantadas na Etapa 1. A tese central desta versão do relatório — a distinção entre "limitação teórica documentada na literatura" e "violação encontrada empiricamente nos dados" — foi definida como decisão de projeto ("Naive Bayes puro", `CLAUDE.md`) antes da geração dos dados, não inferida depois de olhar os resultados. Todo o conteúdo é defensável oralmente.